

Procesamiento de imágenes en la detección de LLA

Juan David Hernández Prieto, Juan Sebastian Díaz Mora, Sofía Dayhane Velandia Sierra

Universidad Sergio Arboleda
Facultad de Ciencias exactas e ingeniería
Curso de Procesamiento de imágenes

I. DEFINICIÓN DEL PROBLEMA

Detección de Leucemia Linfoblástica Aguda en Frotis Sanguíneos mediante Procesamiento de Imágenes

A. Contexto y relevancia

La Leucemia Linfoblástica Aguda (LLA) es el cáncer pediátrico más frecuente, aunque puede afectar a personas de todas las edades. Se caracteriza por la proliferación descontrolada de células inmaduras en la sangre, conocidas como blastos leucémicos, que son glóbulos blancos inmaduros. Uno de los principales exámenes para su diagnóstico es el frotis sanguíneo, el cual permite identificar la presencia anormal de blastos cuando su cantidad supera un umbral específico.[1]

El diagnóstico tradicional de ALL es un proceso lento y subjetivo, ya que requiere que un especialista analice manualmente las muestras de sangre. Este método puede ser poco eficiente y propenso a errores. En este contexto, el procesamiento de imágenes surge como una alternativa para automatizar la detección de blastos leucémicos, permitiendo segmentar y visualizar mejor las células anormales.

Este proyecto tiene como objetivo detectar ALL a través de técnicas de detección y segmentación de blastos leucémicos en frotis sanguíneos, mejorando así la precisión y eficiencia del análisis, por medio de transformaciones específicas con respecto a la intensidad, segmentación, escala de la imagen y el uso de algoritmos de aprendizaje profundo en el análisis de la imagen.

II. JUSTIFICACION Y SOPORTE TEÓRICO

A. Preguntas de justificación

1) *¿Por qué este problema es relevante?:* El ALL representa el 75 por ciento de casos de cáncer en los niños con incidencia entre los 2 a los 5 años. Con un tasa de supervivencia que ha mejorado a través de los años, en gran medida gracias a los diagnósticos tempranos de la enfermedad [1]. El uso de procesamiento de imágenes en el proceso de diagnóstico permite una automatización que reduce el error humano en la intervención tradicional subjetiva

de un especialista, evaluaciones preliminares más asequibles para hospitales sin tanto recursos. Y mucha más eficiencia en el tratamiento.

2) *¿Qué impacto tiene su resolución en el contexto actual?:* En los últimos años, se han desarrollado y probado métodos basados en redes convolucionales para la detección temprana de la leucemia linfoblástica aguda (LLA), logrando una precisión del 93.4 por ciento en la identificación de la enfermedad [2]. Estos avances son fundamentales para futuras investigaciones y para demostrar la eficacia de estos enfoques, que permiten un análisis más profundo de las imágenes médicas mediante inteligencia artificial, superando las limitaciones del ojo humano. Además, otra técnica que ha mostrado avances significativos en la toma de decisiones clínicas en distintos tipos de cáncer es la extracción de características radiómicas [3].

3) *¿Qué dificultades presentan los métodos tradicionales para resolverlo?:* Hay varios tipos de exámenes que se realizan de manera tradicional que van desde **frotis Sanguíneo con microscopía** hasta la **biopsia de médula ósea**, sin embargo, estos métodos de diagnóstico pueden llevar las siguientes dificultades:

- Capacitación especializada de los examinadores
- Altos Costos en el proceso diagnóstico
- Subjetividad del especialista
- Largos tiempos para ser diagnosticado

Ha comparación de usar técnicas de procesamiento de imágenes.

B. Referencias de trabajos previos

Los estudios previos encontrados, se dividieron en dos. Los estudios que proponen un paso a paso de procesamiento con técnicas ya establecidas y el segundo presenta una variación en la aplicación de algoritmos de aprendizaje profundo en su realización.

1) *Exploración de metodologías de procesamiento de imágenes:* Primer procesamiento, se aplicó reducción de ruido mediante FastNIMeansDenoisingColoured, seguida de la separación de canales RGB, eliminando el canal verde para mejorar el contraste de los glóbulos

blancos. Luego, se realizó la segmentación de bordes utilizando el operador Canny junto con operaciones morfológicas de dilatación y cierre para eliminar el fondo. Posteriormente, la segmentación del núcleo celular se llevó a cabo mediante umbralización binaria combinada con Otsu. Se extrajeron características geométricas, de textura y estadísticas de las células segmentadas. Finalmente, el algoritmo K-Nearest Neighbour (KNN) se utilizó para clasificar las células en normales o blastos leucémico.[4]

El segundo procesamiento fue este estudio. Primero, se realiza la segmentación de glóbulos blancos mediante el método watershed con control de marcadores. Luego, para la segmentación del núcleo y citoplasma, se usa un algoritmo de clustering basado en medidas discriminantes (SDM), optimizado con Algoritmos Genéticos (GA). En la extracción de características, se calculan 80 atributos, incluyendo geométricos (área del núcleo, relación núcleo/citoplasma), texturales (matriz GLCM: contraste, entropía, homogeneidad) y colorimétricos (espacio CIELAB). Finalmente, en la clasificación de células, se prueban distintos modelos, destacando SVM con kernel RBF y el Dempster-Shafer ensemble, que logran una precisión superior al 96 por ciento. [5]

Este estudio desarrolla un prototipo de visión por computadora para la detección temprana de blastos leucémicos en sangre periférica. En el preprocesamiento, se utiliza el filtro Canny para detección de bordes y se aplican filtros de reducción de ruido en OpenCV. La segmentación de blastos se realiza mediante umbralización y detección de contornos, clasificando las células con Máquinas de Vectores de Soporte (SVM). Para el entrenamiento y validación, se usaron imágenes de Google debido a la falta de bases de datos clínicas, implementando SVM con scikit-learn y almacenando el modelo con Joblib para su reutilización. Aunque el prototipo representa un avance en la detección automatizada de blastos, la precisión está limitada por la falta de datos clínicos.[6]

2) *Exploracion de modelos usados para el procesamiento de imagenes:* El estudio "Deep Learning Algorithms for Early Diagnosis of Acute Lymphoblastic Leukemia" [2] evaluó diez arquitecturas CNN, determinando que DenseNet201 fue la más eficiente en la clasificación de LLA, con una precisión superior al 99.85 por ciento debido a su capacidad para extraer características profundas y evitar el problema del gradiente desaparecido. En contraste, "A Hybrid Deep Learning Architecture for Leukemic B-lymphoblast Classification" [7] propuso una arquitectura híbrida CNN-LSTM, donde VGG-16 fue utilizado para la extracción de características

y LSTM para capturar dependencias espaciales y secuenciales en las imágenes, logrando mejoras en la clasificación de linfoblastos leucémicos B. Sin embargo, el anterior mostró una mayor precisión general, ya que las LSTM en el metodo hibrido se requieren más datos secuenciales para su óptimo desempeño, lo que puede afectar la robustez en conjuntos de datos limitados. Las redes CNN son los modelos mas comunes encontrados en estudios anteriores. Tienen una mayor precision.

III. DEFINICIÓN DE DATOS

A. Fuente de los datos

Existen un sin fin de bases de datos públicas que facilitan el desarrollo en el área de la investigación en proyectos aplicados en el sector del procesamiento de imágenes médicas. Entre ellas se conocen ImageNet, COCO y un grupo particular de imágenes en el storage de Kaggle. Hay que tener en cuenta que estas bases de datos proporcionan información etiquetada que permite desarrollar técnicas como procesamiento de imágenes y análisis de las mismas.

Para este proyecto, se decidió utilizar el conjunto de imágenes de *Acute Lymphoblastic Leukemia (ALL)*, que se encuentra disponible en la plataforma de Kaggle. Este grupo de imágenes médicas permite realizar investigaciones para mejorar la precisión del diagnóstico para pacientes con ALL, usando técnicas de procesamiento de imágenes para obtener un mejor análisis.

B. Características de los datos

1) Número de muestras disponibles y formato:

En total, el dataset se compone por 3256 imágenes en formato JPG, con tres canales RGB. El conjunto de datos se divide en 2 clases. Benigna (benign), Compreendida por hematogones. Cuenta con 504 imágenes. Y maligna (malignant), Donde se agrupan las imágenes en 3 subgrupos identificados por el subtipo de linfoblasto maligno. El primero, LLA Pre-B temprana (Early), compuesto por 985 imágenes; el segundo, Pre-B (Pre), comprendido por 963 imágenes; y finalmente Pro-B (Pro) con 804 imágenes. Las muestras tienen una resolución de (224 X 224) píxeles.




Fig. 1. Muestras benignas vs malignas

2) *Posibles desafíos*: En los posibles desafíos que encontramos dentro de las imágenes, sucede que las muestras malignas se ven notoriamente distintas a las muestras benignas. La principal diferencia entre ambas imágenes es el color en general. También, en las muestras malignas los linfocitos se ven más oscuros a diferencia de como aparecen en las muestras benignas, donde se ven de un color mas suave y en gran parte transparentes. Debido a estos importantes cambios, se deben aplicar cuidadosamente las técnicas de transformación para obtener resultados similares independientemente de las diferencias en las muestras originales.



Fig. 2. Imagen final esperada

REFERENCES

- [1] A. Emadi and J. Y. Law, "Leucemia linfoblástica aguda (LLA)", *Manual MSD Versión para Profesionales*, October 2023. [En línea]. Disponible en: <https://www.msdmanuals.com/es/professional/hematolog%C3%ADa-y-oncolog%C3%ADa/leucemias/leucemia-linfobl%C3%A1stica-aguda-lla>. [Accedido: 10-mar-2025].
- [2] D. Papaioannou, I. Christou, N. Anagnou, y A. Chatziioannou, "Deep Learning Algorithms for Early Diagnosis of Acute Lymphoblastic Leukemia," *arXiv preprint*, arXiv:2407.10251, 2024. [En línea]. Disponible en: <https://arxiv.org/abs/2407.10251>. [Accedido: 10-mar-2025].
- [3] S. Chin Neoh, W. Srisukkhram, L. Zhang, et al., "An Intelligent Decision Support System for Leukaemia Diagnosis using Microscopic Blood Images," *Scientific Reports*, vol. 5, no. 14938, 2015. [En línea]. Disponible en: <https://doi.org/10.1038/srep14938>. [Accedido: 10-mar-2025].
- [4] S. Chin Neoh, W. Srisukkhram, L. Zhang, et al., "An Intelligent Decision Support System for Leukaemia Diagnosis using Microscopic Blood Images," in **Proceedings of the International Research Conference*, General Sir John Kotelawala Defence University, 2015. [En línea]. Disponible en: <http://ir.kdu.ac.lk/handle/345/1695>. [Accedido: 10-mar-2025].*
- [5] S. Chin Neoh, W. Srisukkhram, L. Zhang, et al., "An Intelligent Decision Support System for Leukaemia Diagnosis using Microscopic Blood Images," *Scientific Reports*, vol. 5, no. 14938, 2015. [En línea]. Disponible en: <https://doi.org/10.1038/srep14938>. [Accedido: 10-mar-2025].
- [6] A. Hernández-Gómez, I. M. Velasco-Rodríguez, F. G. Martínez-Rangel, y L. A. Alonso-Hernández, "Desarrollo de un prototipo de detección de células blásticas en muestras de sangre periférica mediante visión por computadora," *Revista Científica de Ingenierías y Arquitectura*, vol. 3, no. 1, pp. 22-37, 2024. [En línea]. Disponible en: <http://ir.kdu.ac.lk/handle/345/1695>. [Accedido: 10-mar-2025].
- [7] H. M. A. Ahmed, A. A. Osman, y M. N. Mohammed, "A Hybrid Deep Learning Architecture for Leukemic B-lymphoblast Classification," *arXiv preprint*, arXiv:1909.11866, 2019. [En línea]. Disponible en: <https://arxiv.org/abs/1909.11866>. [Accedido: 10-mar-2025].