

Procesamiento de imágenes en la detección de LLA

Juan David Hernández Prieto, Juan Sebastian Díaz Mora, Sofía Dayhane Velandia Sierra

Universidad Sergio Arboleda
Facultad de Ciencias exactas e ingeniería
Curso de Procesamiento de imágenes

I. DEFINICIÓN DEL PROBLEMA

Detección de Leucemia Linfoblástica Aguda en Frotis Sanguíneos mediante Procesamiento de Imágenes

A. Contexto y relevancia

La Leucemia Linfoblástica Aguda (LLA) es el cáncer pediátrico más frecuente, aunque puede afectar a personas de todas las edades. Se caracteriza por la proliferación descontrolada de células inmaduras en la sangre, conocidas como blastos leucémicos, que son glóbulos blancos inmaduros. Uno de los principales exámenes para su diagnóstico es el frotis sanguíneo, el cual permite identificar la presencia anormal de blastos cuando su cantidad supera un umbral específico.[1]

El diagnóstico tradicional de ALL es un proceso lento y subjetivo, ya que requiere que un especialista analice manualmente las muestras de sangre. Este método puede ser poco eficiente y propenso a errores. En este contexto, el procesamiento de imágenes surge como una alternativa para automatizar la detección de blastos leucémicos, permitiendo segmentar y visualizar mejor las células anormales.

Este proyecto tiene como objetivo detectar ALL a través de técnicas de detección y segmentación de blastos leucémicos en frotis sanguíneos, mejorando así la precisión y eficiencia del análisis, por medio de transformaciones específicas con respecto a la intensidad, segmentación, escala de la imagen y el uso de algoritmos de aprendizaje profundo en el análisis de la imagen.

II. JUSTIFICACION Y SOPORTE TEÓRICO

A. Preguntas de justificación

1) *¿Por qué este problema es relevante?*: El ALL representa el 75 por ciento de casos de cáncer en los niños con incidencia entre los 2 a los 5 años. Con un tasa de supervivencia que ha mejorado a través de los años, en gran medida gracias a los diagnósticos tempranos de la enfermedad [1]. El uso de procesamiento de imágenes en el proceso de diagnóstico permite una automatización que reduce el error humano en la intervención tradicional subjetiva

de un especialista, evaluaciones preliminares más asequibles para hospitales sin tanto recursos. Y mucha más eficiencia en el tratamiento.

2) *¿Qué impacto tiene su resolución en el contexto actual?*: En los últimos años, se han desarrollado y probado métodos basados en redes convolucionales para la detección temprana de la leucemia linfoblástica aguda (LLA), logrando una precisión del 93.4 por ciento en la identificación de la enfermedad [2]. Estos avances son fundamentales para futuras investigaciones y para demostrar la eficacia de estos enfoques, que permiten un análisis más profundo de las imágenes médicas mediante inteligencia artificial, superando las limitaciones del ojo humano. Además, otra técnica que ha mostrado avances significativos en la toma de decisiones clínicas en distintos tipos de cáncer es la extracción de características radiómicas [3].

3) *¿Qué dificultades presentan los métodos tradicionales para resolverlo?* : Hay varios tipos de exámenes que se realizan de manera tradicional que van desde **frotis Sanguíneo con microscopía** hasta la **biopsia de médula ósea**, sin embargo, estos métodos de diagnóstico pueden llevar las siguientes dificultades:

- Capacitación especializada de los examinadores
- Altos Costos en el proceso diagnóstico
- Subjetividad del especialista
- Largos tiempos para ser diagnosticado

Ha comparación de usar técnicas de procesamiento de imágenes.

B. Referencias de trabajos previos

Los estudios previos encontrados, se dividieron en dos. Los estudios que proponen un paso a paso de procesamiento con técnicas ya establecidas y el segundo presenta una variación en la aplicación de algoritmos de aprendizaje profundo en su realización.

1) *Exploración de metodologías de procesamiento de imágenes*: Primer procesamiento, se aplicó reducción de ruido mediante FastNIMeansDenoisingColoured, seguida de la separación de canales RGB, eliminando el canal verde para mejorar el contraste de los glóbulos

blancos. Luego, se realizó la segmentación de bordes utilizando el operador Canny junto con operaciones morfológicas de dilatación y cierre para eliminar el fondo. Posteriormente, la segmentación del núcleo celular se llevó a cabo mediante umbralización binaria combinada con Otsu. Se extrajeron características geométricas, de textura y estadísticas de las células segmentadas. Finalmente, el algoritmo K-Nearest Neighbour (KNN) se utilizó para clasificar las células en normales o blastos leucémico.[4]

El segundo procesamiento fue este estudio. Primero, se realiza la segmentación de glóbulos blancos mediante el método watershed con control de marcadores. Luego, para la segmentación del núcleo y citoplasma, se usa un algoritmo de clustering basado en medidas discriminantes (SDM), optimizado con Algoritmos Genéticos (GA). En la extracción de características, se calculan 80 atributos, incluyendo geométricos (área del núcleo, relación núcleo/citoplasma), texturales (matriz GLCM: contraste, entropía, homogeneidad) y colorimétricos (espacio CIELAB). Finalmente, en la clasificación de células, se prueban distintos modelos, destacando SVM con kernel RBF y el Dempster-Shafer ensemble, que logran una precisión superior al 96 por ciento. [5]

Este estudio desarrolla un prototipo de visión por computadora para la detección temprana de blastos leucémicos en sangre periférica. En el preprocesamiento, se utiliza el filtro Canny para detección de bordes y se aplican filtros de reducción de ruido en OpenCV. La segmentación de blastos se realiza mediante umbralización y detección de contornos, clasificando las células con Máquinas de Vectores de Soporte (SVM). Para el entrenamiento y validación, se usaron imágenes de Google debido a la falta de bases de datos clínicas, implementando SVM con scikit-learn y almacenando el modelo con Joblib para su reutilización. Aunque el prototipo representa un avance en la detección automatizada de blastos, la precisión está limitada por la falta de datos clínicos.[6]

2) *Exploracion de modelos usados para el procesamiento de imagenes:* El estudio "Deep Learning Algorithms for Early Diagnosis of Acute Lymphoblastic Leukemia" [2] evaluó diez arquitecturas CNN, determinando que DenseNet201 fue la más eficiente en la clasificación de LLA, con una precisión superior al 99.85 por ciento debido a su capacidad para extraer características profundas y evitar el problema del gradiente desaparecido. En contraste, "A Hybrid Deep Learning Architecture for Leukemic B-lymphoblast Classification" [7] propuso una arquitectura híbrida CNN-LSTM, donde VGG-16 fue utilizado para la extracción de características

y LSTM para capturar dependencias espaciales y secuenciales en las imágenes, logrando mejoras en la clasificación de linfoblastos leucémicos B. Sin embargo, el anterior mostró una mayor precisión general, ya que las LSTM en el método híbrido se requieren más datos secuenciales para su óptimo desempeño, lo que puede afectar la robustez en conjuntos de datos limitados. Las redes CNN son los modelos más comunes encontrados en estudios anteriores. Tienen una mayor precisión.

III. DEFINICIÓN DE DATOS

A. Fuente de los datos

Existen numerosas bases de datos públicas, como ImageNet, COCO y conjuntos en Kaggle, que ofrecen imágenes etiquetadas para desarrollar técnicas de procesamiento y análisis de imágenes médicas. Para este proyecto se optó por utilizar el conjunto de imágenes de *Acute Lymphoblastic Leukemia (ALL)* de Kaggle, el cual facilita investigaciones orientadas a mejorar la precisión diagnóstica de esta enfermedad.

B. Explicación de las técnicas a usar

Conversión al Espacio de Color HSV: La imagen original, adquirida en el espacio de color RGB, fue objeto de una conversión al espacio de color HSV (Tono, Saturación, Valor). Dicha transformación genera la separación entre la información cromática (tono y saturación) y la luminosidad (valor), lo que optimiza la segmentación cromática. La delimitación de rangos cromáticos específicos, destacándose el tono púrpura vinculado a los núcleos teñidos, se vuelve más factible dentro del espacio HSV.

Umbralización del Color: Se implementó una operación de umbralización del color con el propósito de aislar los núcleos celulares, fundamentándose en sus atributos cromáticos en el espacio HSV. Mediante la selección de un rango específico de valores de tono y saturación congruentes con la tinción púrpura, se preservaron los píxeles constitutivos de los núcleos, mientras que los restantes fueron excluidos. Esto resultó en la segmentación eficaz de los núcleos, separándolos del fondo y otros componentes celulares.

Segmentación y Binarización: Subsecuente a la umbralización del color, la imagen fue sometida a una segmentación adicional, con el fin de depurar las fronteras de los núcleos identificados. Este proceso corroboró la separación precisa de los núcleos respecto del fondo circundante. Acto seguido, se ejecutó la binarización, transformando la imagen en una representación monocromática. A los píxeles correspondientes a los núcleos se les asignó un valor de luminosidad elevado, mientras que los demás píxeles se establecieron en negro. Esta etapa racionalizó la imagen, posibilitando el análisis cuantitativo ulterior.

C. Características de los datos

1) Número de muestras disponibles y formato:

En total, el dataset se compone por 3256 imágenes en formato JPG, con tres canales RGB. El conjunto de datos se divide en 2 clases. Benigna (benign), Compreendida por hematogones. Cuenta con 504 imágenes. Y maligna (malignant), Donde se agrupan las imágenes en 3 subgrupos identificados por el subtipo de linfoblasto maligno. El primero, LLA Pre-B temprana (Early), compuesto por 985 imágenes; el segundo, Pre-B (Pre), comprendido por 963 imágenes; y finalmente Pro-B (Pro) con 804 imágenes. Las muestras tienen una resolución de (224 X 224) píxeles.




Fig. 1. Imágenes en cada fase

2) Posibles desafíos: Las imágenes iniciales presentan variaciones de color y contraste que dificultan la delimitación de las células, y en etapas avanzadas los tonos son significativamente diferentes, lo cual dificulta la aplicación de algún filtro aplicado estándar que funcione para todas las imágenes. Además de cambios morfológicos sutiles que complican la detección de blastos en etapas tempranas. Asimismo, el ruido o desenfoque añade complejidad en la segmentación, y la saturación o sobreexposición parcial puede ocultar detalles importantes en los bordes celulares.

D. imágenes esperadas




Fig. 2. Imágenes esperadas

Se espera lograr una segmentación rescuable, muestreo de los bordes para identificar las células que me interesan incluso si la umbralización o el procesamiento las elimina como en el caso de la imagen con una leucemia avanzada.

REFERENCES

[1] A. Emadi and J. Y. Law, "Leucemia linfoblástica aguda (LLA)", *Manual MSD Versión para Profesionales*, October 2023. [En línea]. Disponible en: <https://www.msdmanuals.com/es/professional/hematolog%C3%ADa-y-oncolog%C3%ADa/leucemias/leucemia-linfobl%C3%A1stica-aguda-lla>. [Accedido: 10-mar-2025].

[2] D. Papaioannou, I. Christou, N. Anagnostou, y A. Chatziioannou, "Deep Learning Algorithms for Early Diagnosis of Acute Lymphoblastic Leukemia," *arXiv preprint*, arXiv:2407.10251, 2024. [En línea]. Disponible en: <https://arxiv.org/abs/2407.10251>. [Accedido: 10-mar-2025].

[3] S. Chin Neoh, W. Srisukkhom, L. Zhang, et al., "An Intelligent Decision Support System for Leukaemia Diagnosis using Microscopic Blood Images," *Scientific Reports*, vol. 5, no. 14938, 2015. [En línea]. Disponible en: <https://doi.org/10.1038/srep14938>. [Accedido: 10-mar-2025].

[4] S. Chin Neoh, W. Srisukkhom, L. Zhang, et al., "An Intelligent Decision Support System for Leukaemia Diagnosis using Microscopic Blood Images," in *Proceedings of the International Research Conference**, General Sir John Kotelawala Defence University, 2015. [En línea]. Disponible en: <http://ir.kdu.ac.lk/handle/345/1695>. [Accedido: 10-mar-2025].

[5] S. Chin Neoh, W. Srisukkhom, L. Zhang, et al., "An Intelligent Decision Support System for Leukaemia Diagnosis using Microscopic Blood Images," *Scientific Reports*, vol. 5, no. 14938, 2015. [En línea]. Disponible en: <https://doi.org/10.1038/srep14938>. [Accedido: 10-mar-2025].

[6] A. Hernández-Gómez, I. M. Velasco-Rodríguez, F. G. Martínez-Rangel, y L. A. Alonso-Hernández, "Desarrollo de un prototipo de detección de células blásticas en muestras de sangre periférica mediante visión por computadora," *Revista Científica de Ingenierías y Arquitectura*, vol. 3, no. 1, pp. 22-37, 2024. [En línea]. Disponible en: <http://ir.kdu.ac.lk/handle/345/1695>. [Accedido: 10-mar-2025].

[7] H. M. A. Ahmed, A. A. Osman, y M. N. Mohammed, "A Hybrid Deep Learning Architecture for Leukemic B-lymphoblast Classification," *arXiv preprint*, arXiv:1909.11866, 2019. [En línea]. Disponible en: <https://arxiv.org/abs/1909.11866>. [Accedido: 10-mar-2025].